

Introdução ao Machine Learning Aplicado com Scikit-learn e NumPy

Igor Correa Trifilio Campos, Filipe Moreira Vidal, Vitor Hugo Coradini

GET Engenharia Computacional

Estrutura do Minicurso

1. Introdução
2. Pré-processamento
3. Supervisionado
4. Não Supervisionado
5. Validação de Modelos
6. Scikit-Learn

Introdução à Machine Learning

Processo de ensinar um computador a fazer previsões ou tomar decisões a partir de dados, identificando padrões ou regularidades.

Exemplos:

1. Recomendação de Produtos (ex.: Netflix, Amazon)
2. Reconhecimento de Imagens (ex.: diagnóstico médico, reconhecimento facial)
3. Previsão de Séries Temporais (ex.: previsão de demanda, previsão de vendas)

Introdução à Machine Learning

Fluxo de Trabalho

- Pré Processamento
- Treinamento
- Validação



Desenvolvimento no Colab

Link para o acesso ao minicurso no colab
está no site do GET-EngComp:

www2.ufjf.br/getengcomp/

Pré-processamento de Dados

- Dados reais podem conter valores ausentes, variáveis desbalanceadas ou ruídos.
- Preparação, organização e estruturação dos dados.
- Modelos de ML requerem dados bem formatados.

	cargo	idade	salario	bonus	sócio
0	Diretor	45	24000.0	10000.0	sim
1	Analista	22	8000.0	2000.0	não
2	Programador	30	NaN	1000.0	não
3	Gerente	24	15100.0	NaN	não
4	Gerente	30	35000.0	6000.0	sim

Técnicas

- Codificação de variáveis categóricas
- Padronização
- Normalização
- Divisão dos dados

Codificação de variáveis categóricas

Utilizadas para converter variáveis categóricas em uma forma numérica que possa ser utilizada por modelos de Machine Learning.

- Label Encoder.
- One Hot Encoder.

Label Encoder

- Converte variáveis categóricas em valores inteiros.
- Ideal para categorias com uma ordem (variáveis ordinais).

Cor	Label Encoder
Vermelho	0
Verde	1
Azul	2

Tamanho	Label Encoder
Baixo	0
Médio	1
Alto	2

Cor	Tamanho
Vermelho	Baixo
Verde	Médio
Azul	Alto
Vermelho	Alto
Verde	Baixo

Cor Codificada	Tamanho Codificado
0	0
1	1
2	2
0	2
1	0

One Hot Encoder

- Cria uma nova variável binária (0 ou 1) para cada categoria única da variável original.
- Ideal para um número reduzido de categorias e variáveis nominais.

Cor	Tamanho
Vermelho	Baixo
Verde	Médio
Azul	Alto
Vermelho	Alto
Verde	Baixo

Cor_Vermelho	Cor_Verde	Cor_Azul	Tamanho_Baixo	Tamanho_Medio	Tamanho_Alto
1	0	0	1	0	0
0	1	0	0	1	0
0	0	1	0	0	1
1	0	0	0	0	1
0	1	0	1	0	0

Padronização (Z-Score)

- Os dados são transformados de acordo com a distribuição estatística.
- Utiliza a Média e o Desvio Padrão.
- Menos sensível a outliers (valores extremos).
- Pode resultar em valores negativos.

$$X' = \frac{X - \mu}{\sigma}$$

Padronização

Padronização para o exemplo anterior

- Média (μ): 41.0
- Desvio padrão (σ): 19.97

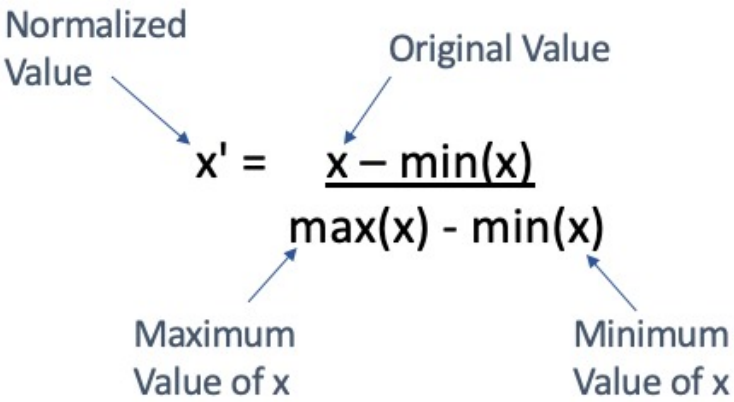
Idade	Padronizados
15	-1,30
20	-1,05
35	-0,30
40	-0,05
47	0,30
50	0,45
80	1,95

Normalização

- Usado para reescalar os valores dos dados para que fiquem dentro de um intervalo específico, geralmente entre 0 e 1.
- Garante que todas as variáveis tenham a mesma escala.
- Evita que variáveis com valores maiores influenciem de forma desproporcional o modelo de Machine Learning.

Normalização Min-Max

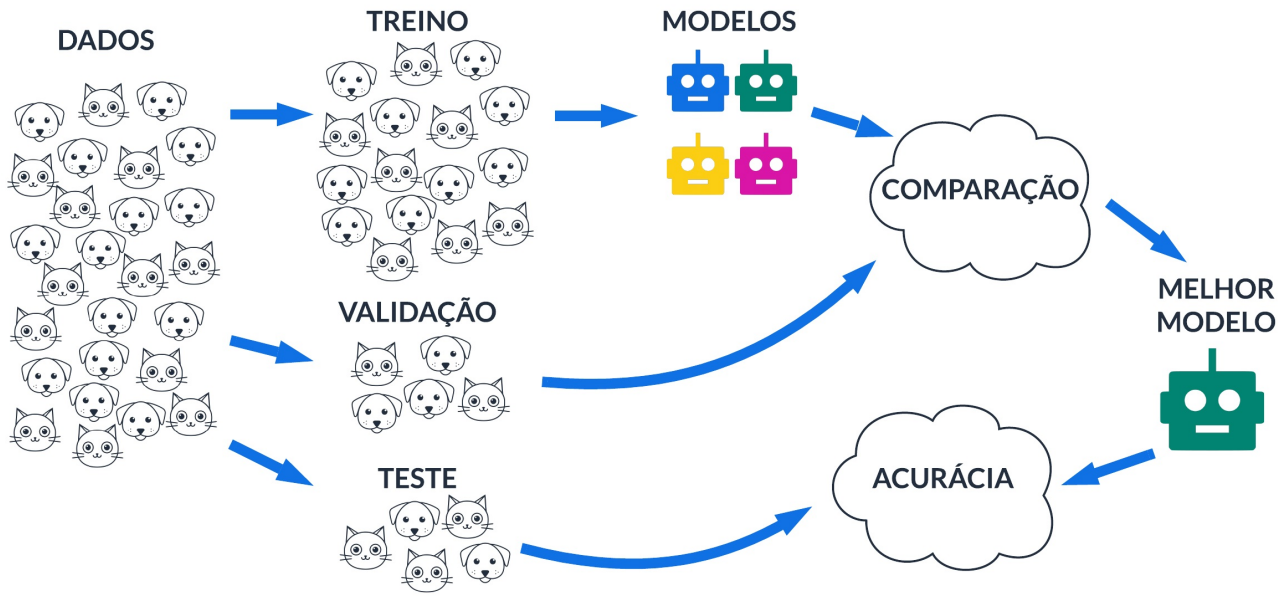
- Um exemplo de normalização min-max é a conversão de idades de um grupo de pessoas para um intervalo entre 0 e 1.
- Se as idades são 15, 20, 35, 40 e 50 anos, o valor mínimo é 15 e o máximo é 50.



Idade	Normalizados
15	0,0000
20	0,0769
35	0,3077
40	0,3846
47	0,4923
50	0,5385
80	1,0000

Divisão dos dados

- **Treinamento:** Usado para ajustar os parâmetros do modelo.
- **Validação:** Usado para avaliar o desempenho do modelo e dos hiperparâmetros durante o treinamento.
- **Teste:** Usado para avaliar a performance final do modelo em dados não vistos durante o treinamento.



Divisão dos dados

Divisão mais comum dos dados que pode variar com base no desempenho do modelo:

- **Treinamento:** 70% - 80% dos dados.
- **Validação:** 10% - 15% dos dados.
- **Teste:** 10% - 15% dos dados.

Tipos de Aprendizado

Aprendizado Supervisionado x Não Supervisionado

- Supervisionado:

O modelo é treinado com dados rotulados, ou seja, dados em que já se sabe a resposta correta. (Regressão, Classificação).

- Não Supervisionado:

O modelo encontra padrões ou grupos sem rótulos, ou seja, dados em que não se sabe a resposta correta. (Clustering/Agrupamento).

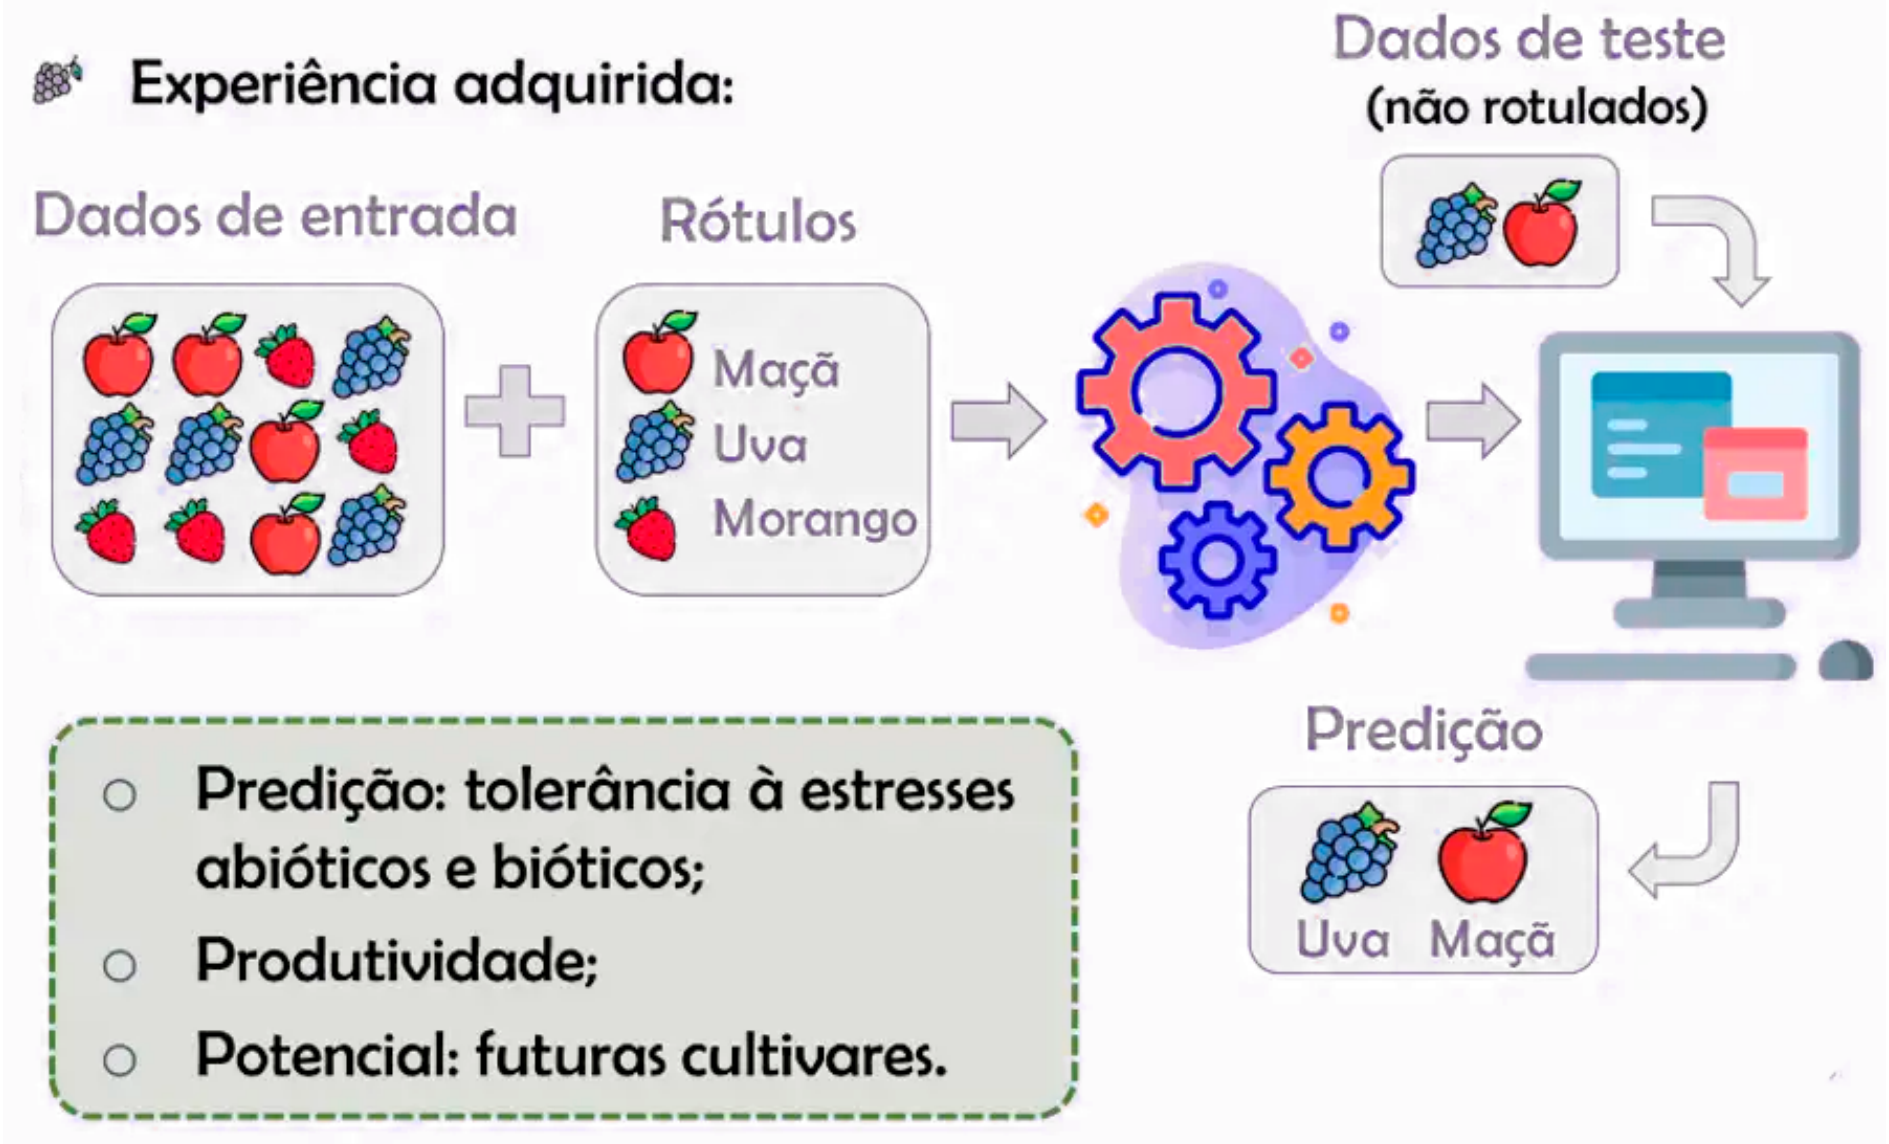
Tipos de Aprendizado







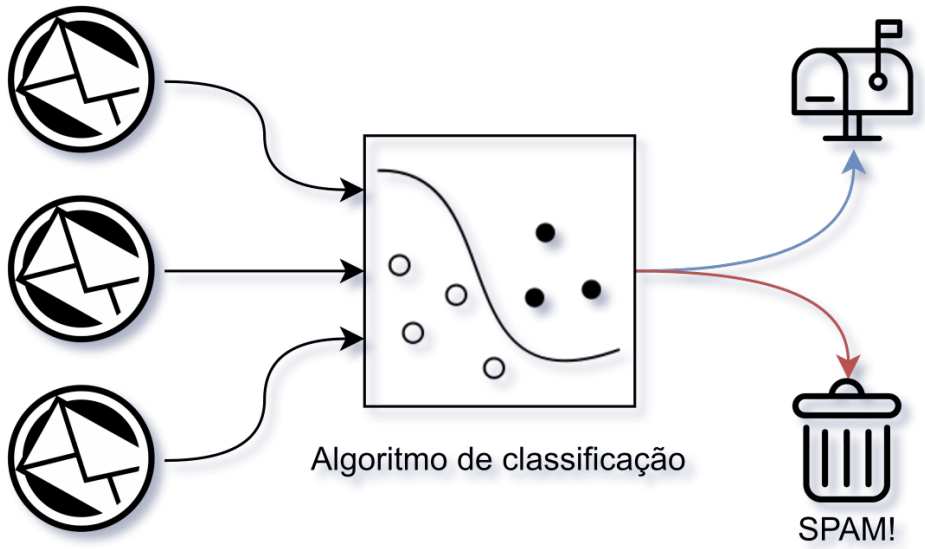
Aprendizado Supervisionado



Classificação

- Entender, reconhecer padrões e agrupar o conjunto de dados em categorias.
- Prever a categoria



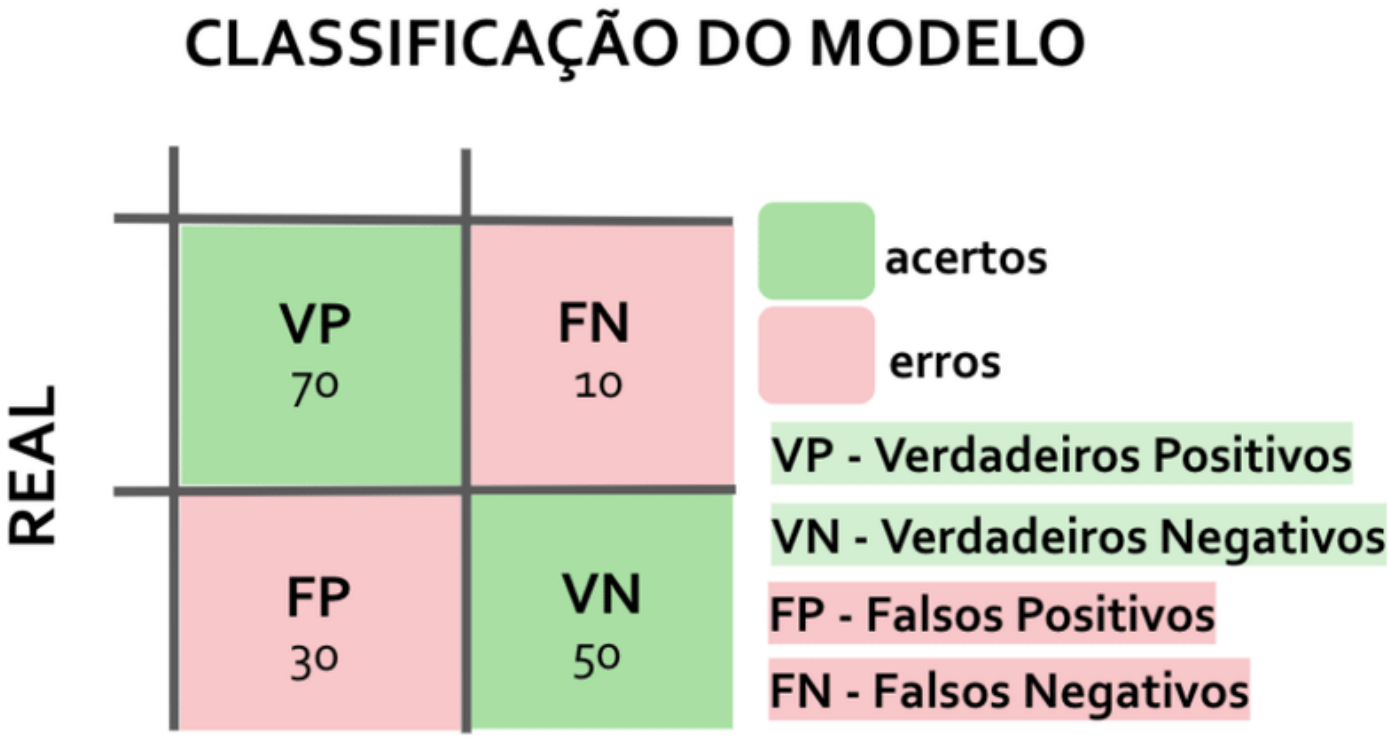


Classificação

Exemplos:

- **Classificação de Gêneros Musicais:** Um modelo pode classificar uma música em múltiplos gêneros (ex.: rock e jazz).
- **Classificação de Rótulos de Produtos:** Atribuir um rótulo (como eletrônicos, vestuário, alimentos) a um produto com base em sua descrição.
- **Diagnóstico Médico:** Um classificador que utilize dados não observados de um paciente e classifique-o como doente ou não-doente.

Matriz de Confusão



Usada para avaliar o desempenho de modelos de classificação.

Acurácia e Precisão

Acurácia

- Mede a proporção de **previsões corretas** (positivas e negativas) em relação ao total de previsões feitas.

$$Acuracia = \frac{VP + VN}{VP + VN + FP + FN}$$

Precisão

- Mede a proporção de **previsões positivas** que estão realmente corretas.
- "Das vezes que o modelo previu positivo, quantas vezes ele estava certo?"

$$Precisao = \frac{VP}{VP + FP}$$

Recall e F1 Score

Recall

- "Dos exemplos realmente positivos, quantos o modelo conseguiu prever corretamente?"

$$Recall = \frac{VP}{VP + FN}$$

F1 Score

- Média harmônica entre Precisão e Recall.
- Equilibra as duas métricas.

$$F1Score = 2 * \frac{Precisao * Recall}{Precisao + Recall}$$

Não devemos olhar só a acurácia!

	Real Positiva	Real Negativa
Prevista Positiva	Verdadeiro Pos.	Falso Pos.
Prevista Negativa	Falso Neg.	Verdadeiro Neg.

	Real "Bom"	Real "Ruim"
Prevista "Bom"	0	0
Prevista "Ruim	10	990

Dataset desbalanceado

- 990 "Ruim"
- 10 "Bom"

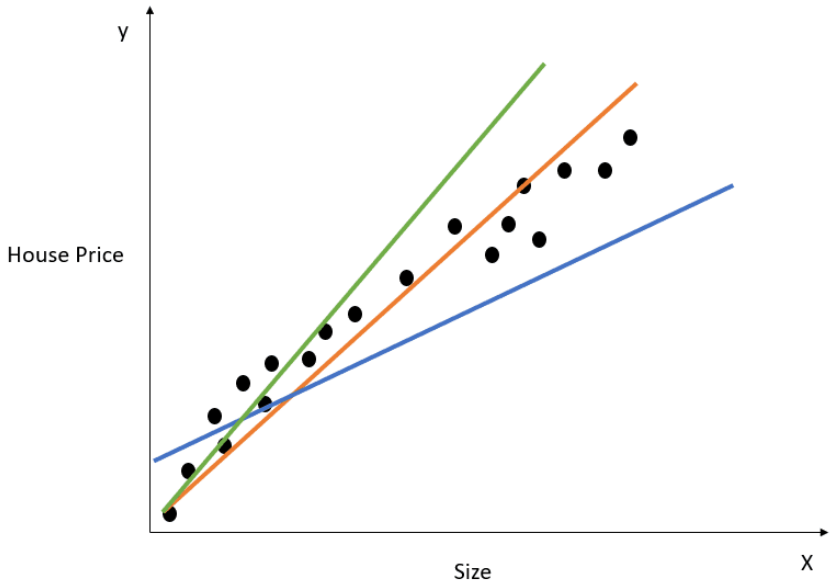
Modelo classifica tudo como "Ruim"

- Acurácia: 99%
- Recall: 0%

Regressão

- Encontrar uma **função** que relacione as variáveis de entrada com a variável de saída.





- A linha **laranja** é a mais próxima de todos os pontos de dados mostrados.
- "Linha de Melhor Ajuste".

Mean Absolut Error - MAE

- Média da diferença entre o real e o previsto.
- valores maiores ou iguais a zero (módulo).

Previsto	Real	Diferença
3,34	3	|0,34|
4,18	4	|0,18|
3	3	|0|
2,99	3	|0,01|
4,51	4,5	|0,01|
5,18	4	|1,18|
8,18	4,5	|3,68|
		5,4

$$MAE = \sum_{I=1}^{N} \frac{|p_i - t_i|}{n}$$

$$MAE = \frac{5,4}{7} = 0,77$$

Root Mean Squared Error - RMSE

- Penaliza erros maiores de forma mais severa (quadrado).
- **Baixo RMSE:** O modelo está prevendo os valores reais com maior precisão.
- **Alto RMSE:** O modelo está cometendo erros significativos nas previsões.

Root Mean Squared Error - RMSE

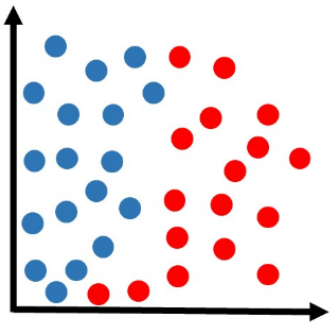
Previsto	Real	Diferença
3,34	3	0,1156
4,18	4	0,0324
3	3	0
2,99	3	1E-04
4,51	4,5	1E-04
5,18	4	1,3924
8,18	4,5	13,5424
		15,083

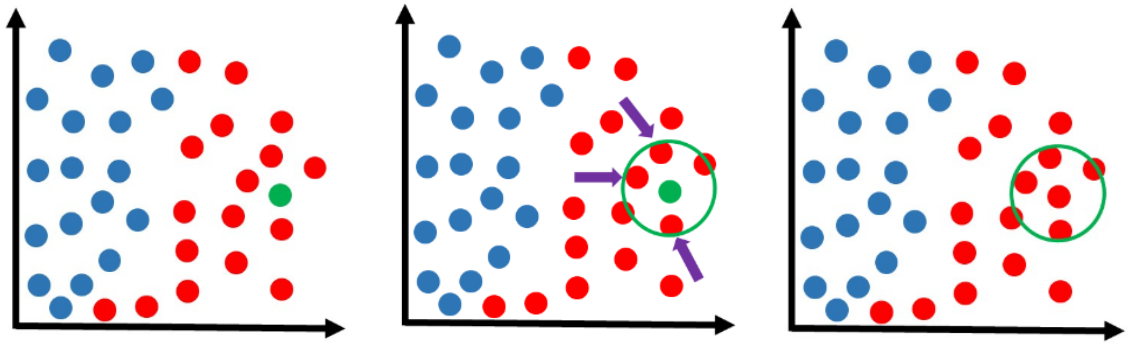
$$\text{RMSE} = \sqrt{\frac{\sum_{I=1}^{N}(p_i - t_i)^2}{N}}$$

$$\text{RMSE} = \sqrt{\frac{15{,}083}{7}}$$

KNN

- K-nearest neighbors, ou “K-vizinhos mais próximos”
- Se os vizinhos mais próximos forem majoritariamente de uma classe, a amostra em questão será classificada nesta categoria.





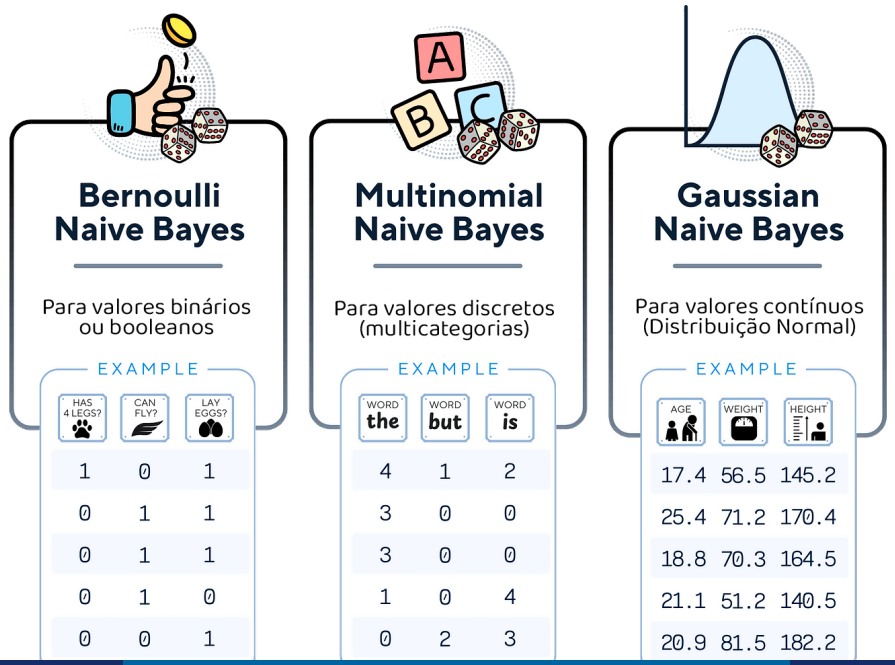
Naive Bayes

- Baseado no Teorema de Bayes de probabilidades condicionais.
- Ideal para casos em que os dados podem se sobrepor entre si

$$P(C|X) = \frac{P(X|C) * P(C)}{P(X)}$$

X: Data, C: Classe

"Qual a chance desse dado pertencer a categoria C dado que ele é um dado X?"



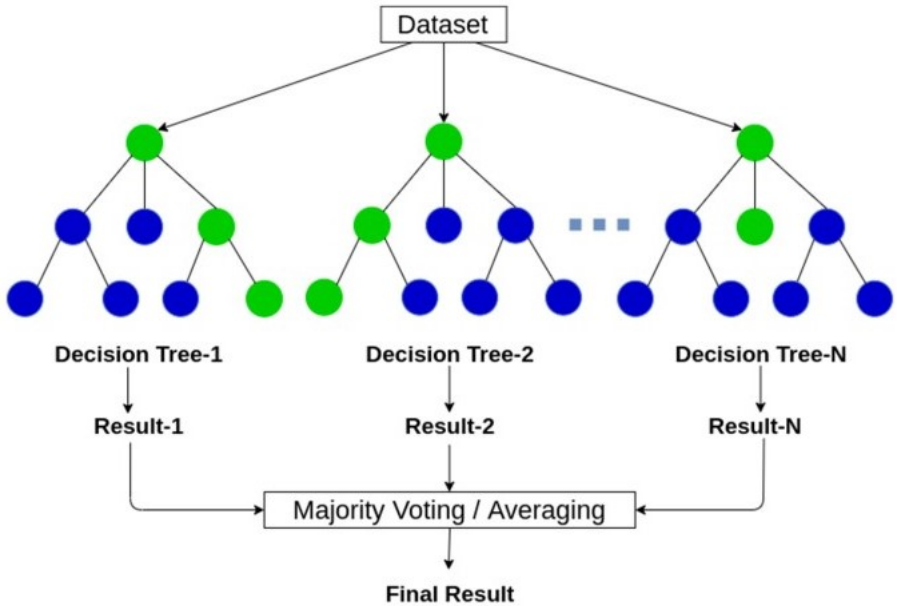
Árvore de Decisão (Decision Trees)

- Vários pontos de decisão serão criados (nós).
- Em cada nó, o resultado da decisão será seguir por um caminho, ou por outro.
- Uma pergunta será feita e teremos duas opções de resposta: sim ou não. A opção “sim” levará a uma próxima pergunta, e a opção “não” a outra.



Floresta Aleatória (Random Florest)

- Técnica de ensemble, ou seja, combina vários modelos para produzir um modelo final mais robusto.
- Constrói múltiplas Árvores de Decisão durante o treinamento e faz a média das previsões para melhorar a precisão e controlar o overfitting.

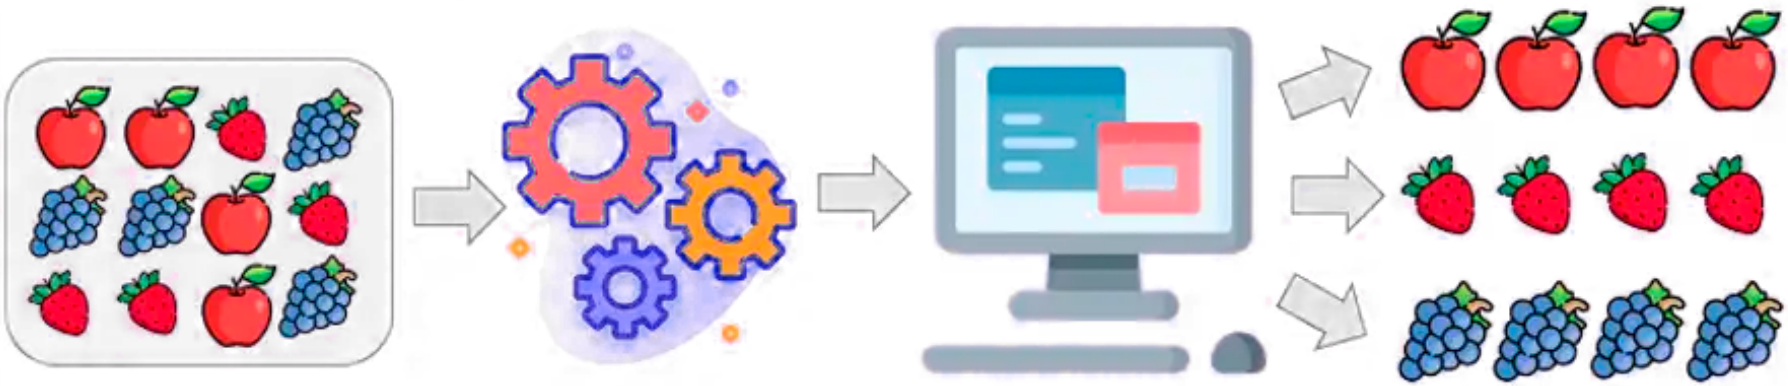


Aprendizado Não Supervisionado

- **Experiência adquirida: Apenas dados de entrada**

Não existe supervisor

Dados de entrada



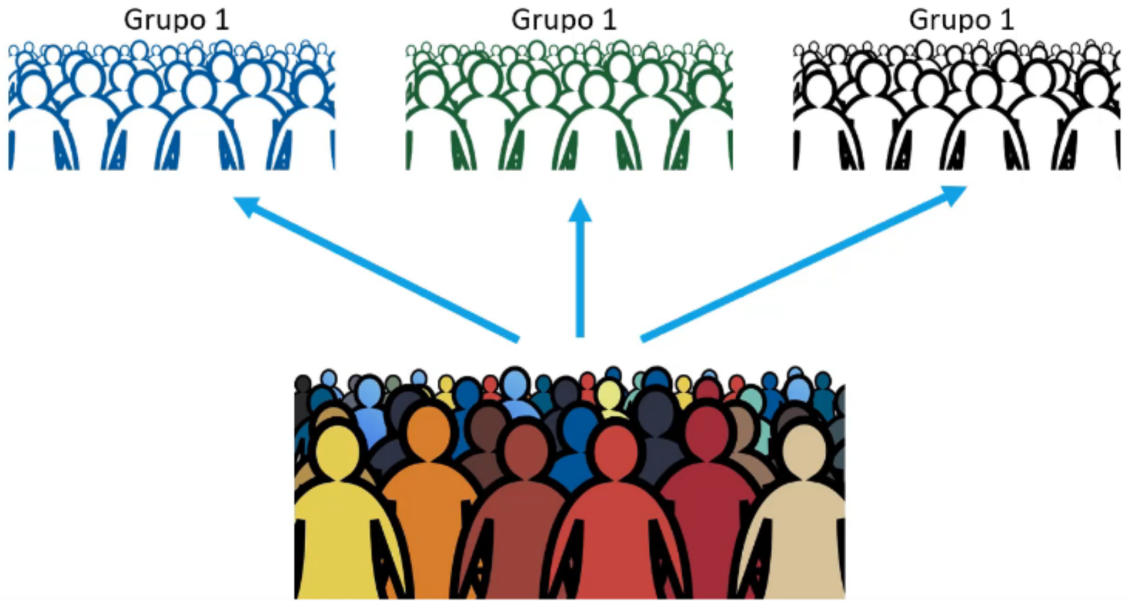
- Análise de agrupamentos;
- Estudos de divergência genética em BAG's.

Visualizar e compreender padrões e tendências dentro de um conjunto de dados

Agrupamento

- Identificar e agrupar dados semelhantes com base em características.
- O modelo organiza os dados em grupos (clusters) sem rótulos predefinidos.





Agrupamento

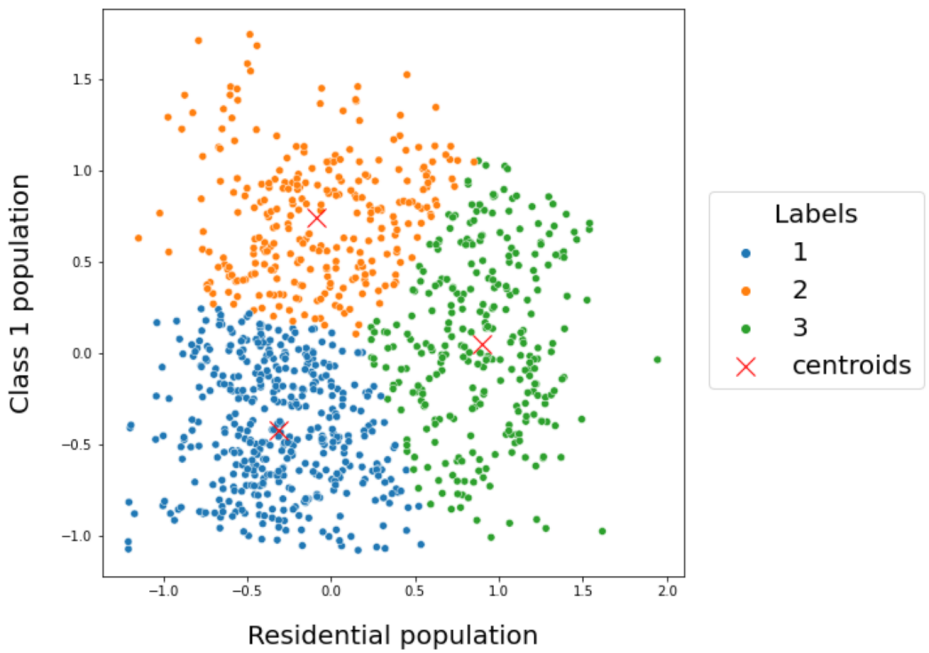
Exemplos:

- **Segmentação de Clientes:** Agrupar clientes com comportamentos similares para personalização de campanhas (ex.: consumidores frequentes e esporádicos).
- **Agrupamento de Imagens:** Organizar imagens com base em semelhanças visuais (ex.: agrupar fotos de paisagens, animais ou objetos).
- **Agrupamento de Dados Geoespaciais:** Agrupar cidades, bairros e regiões com base em características socioeconômicas (renda, mobilidade, infraestrutura) ou ambientais (tipo de solo, cobertura florestal, disponibilidade de água)

Algoritmos K-Means

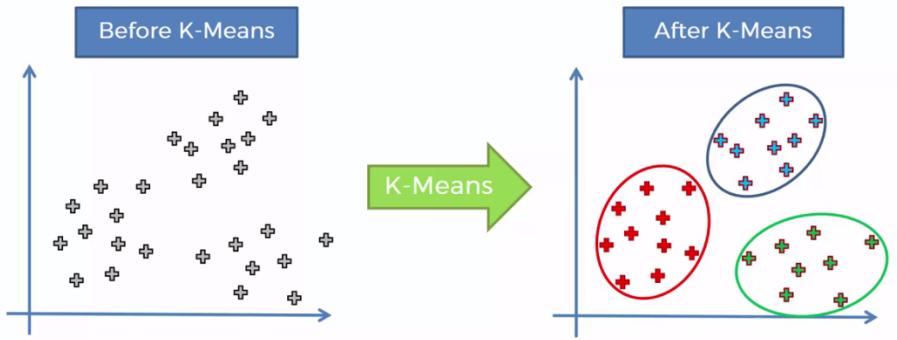
- "K" = Número de centroides (clusters) definidos previamente
- “Means” = Média dos pontos em cada cluster. Determina a posição de seu centroide.

.



Algoritmos K-Means

- Os centroides são posicionado na média dos pontos pertencentes ao seu cluster.
- O algoritmo encontra o centroide mais próximo a um novo ponto.
- O ponto é então classificado como **pertencente ao cluster** daquele centroide.



Métricas de Avaliação do Agrupamento

Inércia (Coesão):

- Mede **o quão próximos os pontos estão** dentro de um mesmo cluster.
- Menores valores = maior densidade.
- Menor distância entre os pontos dentro de um cluster = **maior a inércia** e mais **similares** são entre si.

Separação:

- Avalia a **distância** entre clusters.
- Valores maiores = os clusters estão bem separados.
- Um **bom** agrupamento deve ter **uma alta separação**, significando que os clusters não estão se sobrepondo e são bem distintos entre si.

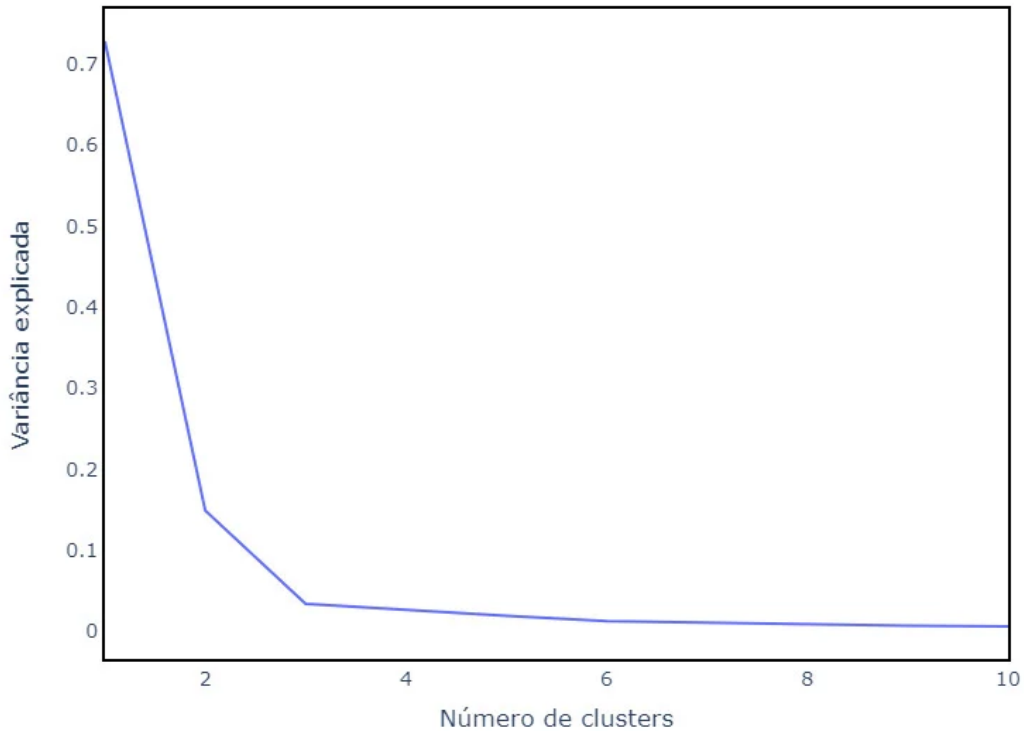
Coeficiente de Silhueta (Silhouette Score)

- Combina a inércia e a separação para fornecer uma **visão balanceada** da clusterização;
- O valor dessa métrica varia de -1 a 1,
- Valor negativo indica que o ponto pode ter sido atribuído ao cluster errado.

$$Silhueta_{\,ponto\ i} = \frac{Inercia_i - Separação_i}{max(Inércia_i, Separação_i)}$$

Método do Cotovelo

- Determina o número ideal de clusters identificando o ponto onde a redução na inércia se torna marginal.



Overfitting (Sobreajuste)

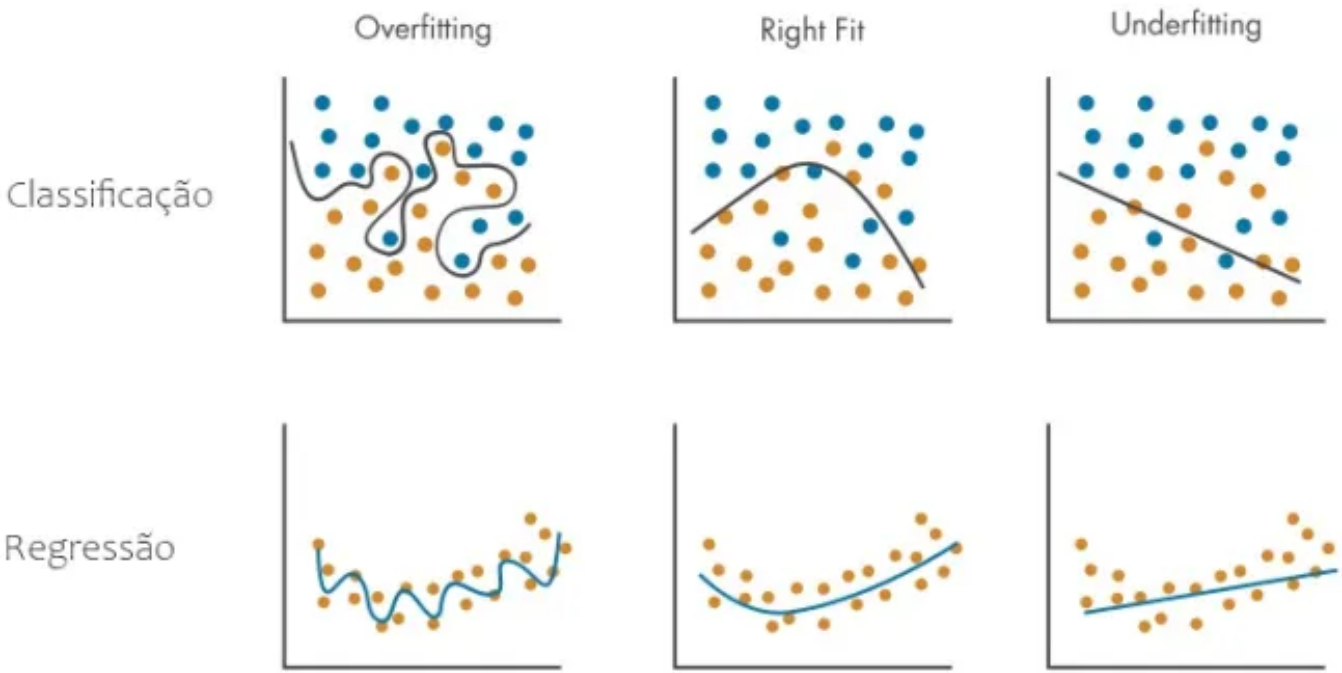
- Previsões precisas para dados de **treinamento**, mas não para **novos dados**.

Alguns motivos:

- O tamanho dos dados de treinamento é muito pequeno.
- Dados de treinamento com grandes quantidades de informações irrelevantes.
- O modelo treina por muito tempo em um único conjunto de dados.
- A **complexidade** do modelo é **alta**, então ele aprende o ruído nos dados de treinamento.

Underfitting (Subajuste)

- O modelo não pode determinar uma relação significativa entre os dados de entrada e saída.
- Fornecem resultados imprecisos tanto para os **dados de treinamento** quanto para o **conjunto de testes**.



Validação de Modelos

A fase de testar o nosso modelo!

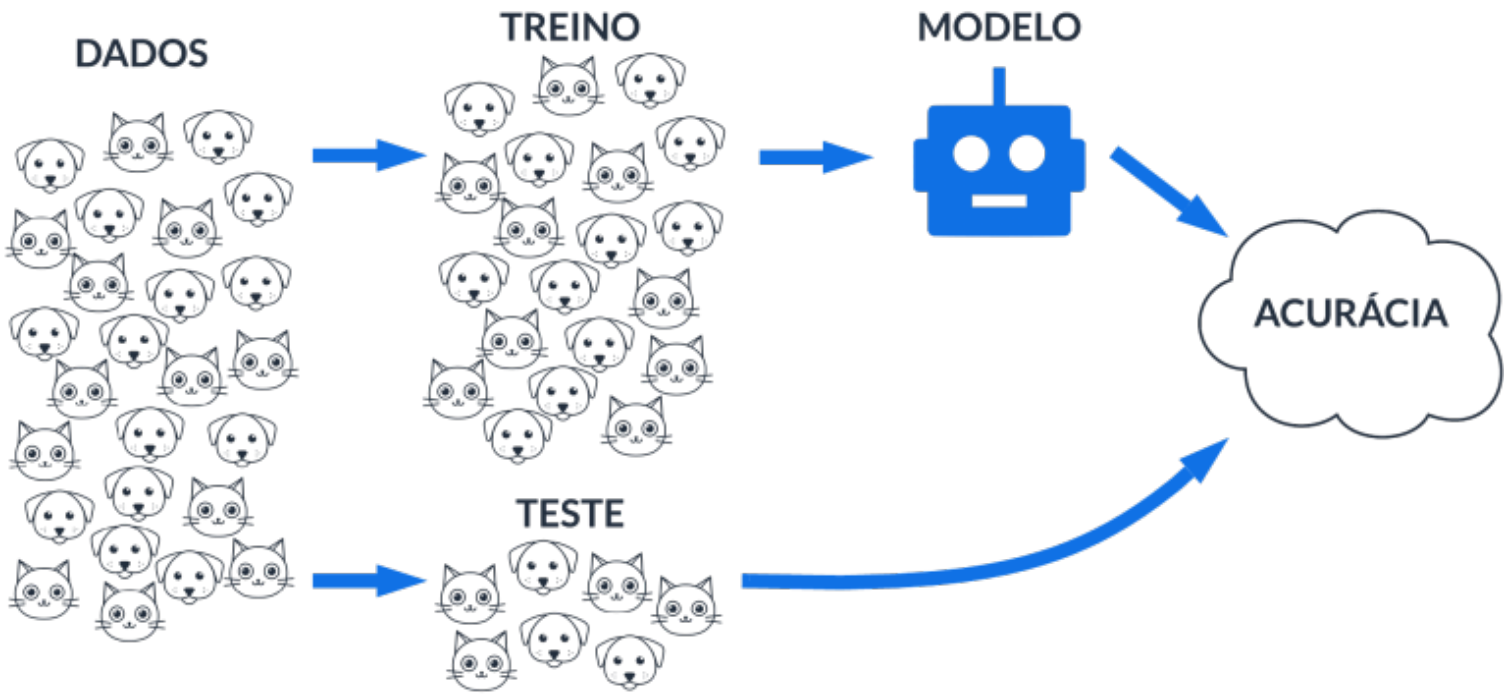
- A validação de modelos avalia o desempenho de um modelo em dados não vistos durante o treinamento.
- Garante que o modelo generalize bem para dados do mundo real.
- Evita problemas como overfitting (superajuste) e underfitting (subajuste).

Técnicas comuns:

- Divisão Treino/Validação/Teste (Hold-out)
- Validação Cruzada (Cross-Validation)

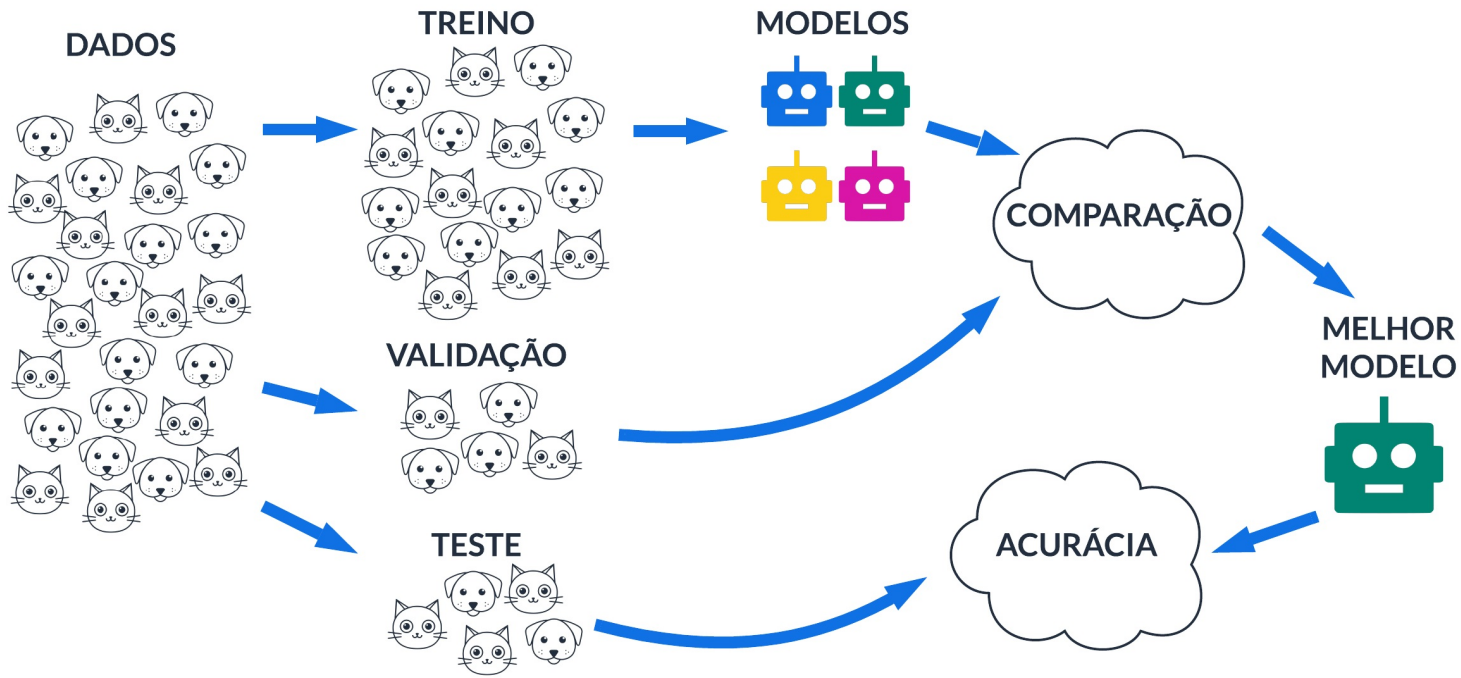
Hold-Out

- Divide o dataset, separando os dados para o Treinamento e para o Teste do modelo.



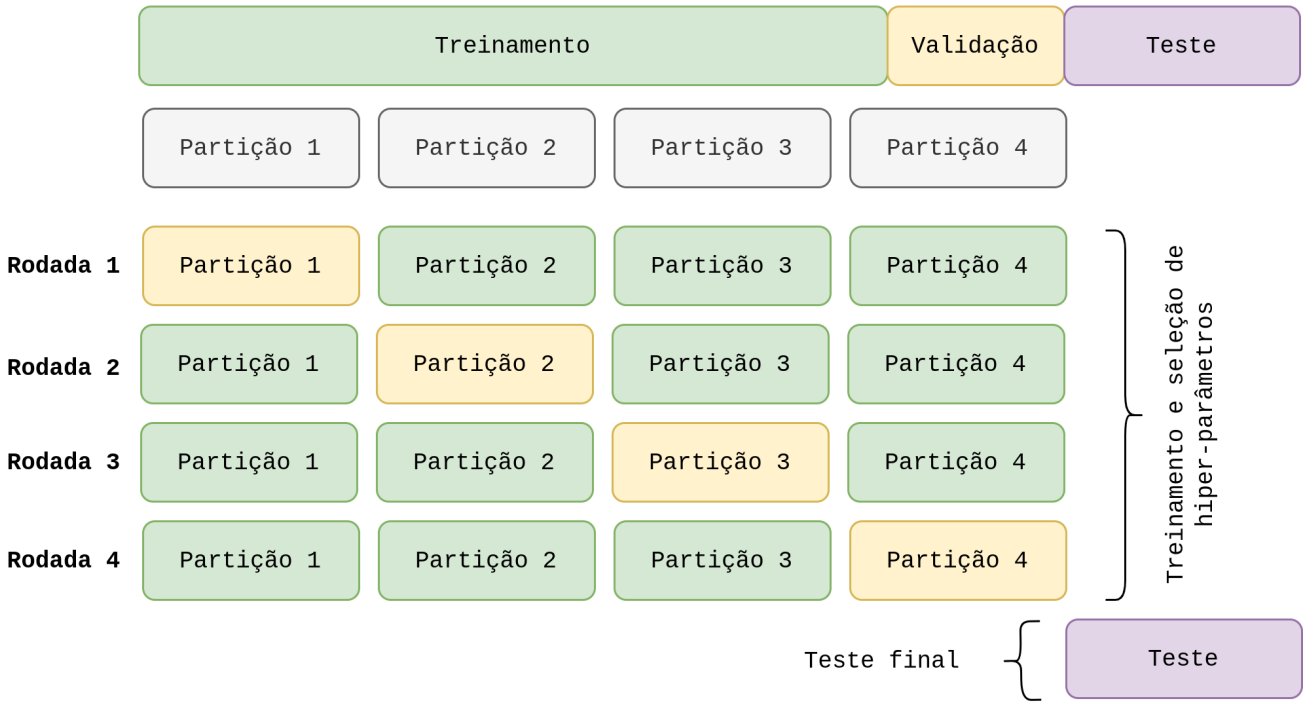
Hold-Out

- Para modelos mais complexos os dados de treinamento são novamente divididos entre Treino e Validação, para ser possível fazer ajustes no modelo sem utilizar dos dados de Teste.



Validação Cruzada (K-fold)

- Divide os dados em múltiplos subconjuntos (folds).
- Treina o modelo em $k - 1$ folds e testa no fold restante.
- Processo repetido k vezes, garantindo que todos os dados sejam usados para treino e teste.



Oque é?

Principais características

Oque vamos abordar



Obrigado pela atenção!